

Classificação de Patologias em Plantas de Soja com Redução de Custo Computacional Utilizando Redes Neurais Convolucionais

Nicolas Reis
Universidade Federal de Viçosa
Email: nicolas.e.silva@ufv.br

Júlia Matos
Universidade Federal de Viçosa
Email: julia.galvao@ufv.br

Abstract—Meeting the growing global demand for soybeans will require a significant increase in agricultural production. Brazil, as the world's largest soybean producer, faces substantial production losses due to the underdiagnosis of foliar diseases, which affect grain quality. Given the high economic importance of soybeans and the challenges involved in diagnosing plant diseases using traditional methods, there is strong potential for automating this process through computer vision and artificial intelligence techniques. Recent approaches in this field often rely on deeper and more complex Convolutional Neural Network (CNN), which limit the accessibility and scalability of such automated solutions. As a way to promote broader access to efficient diagnosis, this paper aims to explore classical CNN architectures, specifically ResNet-58, ResNet-50 and ResNet-101, to determine whether they can deliver performance comparable to that of heavier models. While lightweight models underperformed in accuracy compared to deeper architectures, they demonstrated competitive performance with significantly reduced computational costs, reinforcing their applicability in resource-constrained agricultural scenarios.

I. INTRODUÇÃO

A. Motivação

O levantamento de Wrather e Koenning (2006) [1] indica que o Brasil perde, em média, de 10% a 20% da produção de soja (*Glycine max*) anualmente devido a doenças. Com o objetivo de mitigar esses prejuízos na sojicultura, os métodos de diagnóstico de patologias foliares têm passado por uma reinvenção, utilizando técnicas de visão computacional e aprendizado profundo. Nesse contexto, melhorias significativas na rapidez e precisão da detecção foram alcançadas com o uso de arquiteturas de redes neurais profundas e com muitos parâmetros.

Nosso trabalho fundamenta-se na proposta de investigar redes mais leves e rasas, capazes de obter resultados comparáveis aos das arquiteturas mais complexas, com o intuito de reduzir a complexidade na aplicação de métodos automatizados de diagnóstico precoce. Além disso, a proposta busca viabilizar a geração de dados estatísticos sobre a lavoura, que possam subsidiar o tratamento direcionado e decisões agronômicas mais eficientes.

B. Justificativa para o problema

Apesar dos resultados promissores usando redes neurais convolucionais profundas para o diagnóstico efetivo de

doenças foliares, a maioria das aplicações exige grande capacidade computacional, o que dificulta a adoção desses métodos por produtores com recursos reduzidos. Tendo isso em vista, torna-se relevante buscar alternativas de arquiteturas mais leves que levem a resultados similares aos apresentados por projetos mais complexos, porém com menor custo computacional.

Ademais, por meio dessa classificação eficiente, a geração de dados estatísticos sobre a saúde da lavoura pode fornecer suporte e direcionamento no tratamento eficaz das doenças que mais acometem a produção, contribuindo para o aumento da qualidade e produtividade. Portanto, esse estudo busca preencher uma lacuna ao explorar soluções mais acessíveis sem abrir mão da eficácia.

II. REFERENCIAL TEÓRICO

O trabalho foi baseado em um artigo que busca, através de Redes Neurais Convolucionais (CNN), classificar imagens digitais de doenças de soja [2]. Nesse estudo, os autores utilizaram diferentes arquiteturas que não foram pré-treinadas (Scratch) para solucionar o problema, como, por exemplo, DenseNet-201, EfficientNetB0 e ResNet-50. Para o treinamento proposto por eles, foi utilizado o dataset "ASDID", o qual possui onze classes, sendo duas classes que representam folhas saudáveis e nove classes de diferentes doenças de soja [3]. Em nosso trabalho, utilizamos a mesma base de dados em nossos experimentos, porém buscando uma abordagem diferente da proposta pelos autores.

A fim de reduzir a complexidade das redes usadas pelos pesquisadores supramencionados, buscamos explorar o uso de CNNs clássicas como ResNet-18, ResNet-50 e ResNet-101, arquiteturas mais rasas e/ou com menor quantidade de parâmetros quando comparadas às estruturas usadas no estudo de referência [4]. Entretanto, apesar de utilizarmos três redes diferentes, nosso principal objetivo era reduzir ao máximo a complexidade da arquitetura usada, por essa razão, a ResNet-18 foi o alvo central dos experimentos.

Para nossa análise, utilizamos três conjuntos de dados. O "SoyNet" apresenta divisão binária entre o estado das folhas, saudáveis ou não, e foi o primeiro a ser manipulado com o fim de adaptar os pesos das redes para imagens de plantas

de soja. Os outros datasets usados foram o "SoyBean", com doze classes que separam diferentes enfermidades foliares e uma categoria para folhas saudias, e o "ASDID", o mesmo usado no artigo de referência.

Assim, no treinamento com diferentes datasets e a variação entre problemas multiclasse e de classificação binária, foram usadas técnicas de transferência de aprendizado, como *Fine Tuning* seguido de *Transfer Learning* para a manutenção dos ajustes dos pesos. Ademais, foram realizadas trocas de otimizadores e alterações das taxas de aprendizado, com o objetivo de analisar suas influências.

III. METODOLOGIA

A principal ideia tratada foi a realização de duas tarefas de classificação. Primeiramente, efetuamos *Fine Tuning* em cada arquitetura proposta, utilizando o dataset SoyNet, com o intuito de ajustar os pesos para o complexo problema a ser abordado, de forma que o modelo consiga diferenciar folhas de soja "Saudáveis" e "Doentes" [5]. De maneira sequencial a essa técnica, executamos o *Transfer Learning* nos conjuntos de dados multiclasse, buscando classificar cada doença específica de soja.

A. Fine Tuning no dataset "SoyNet" [5]

Nosso ponto de partida foi o *Fine Tuning* nas arquiteturas. Para isso, utilizamos as redes pré-treinadas com o ImageNetV1 [6], de forma que toda a arquitetura passasse por um processo de congelamento, exceto o último bloco residual (*Layer4*) e a camada de classificação (*Fully Connected*). Dessa forma, espera-se que o modelo ajuste seus pesos e parâmetros do treinamento para o novo problema multiclassificador.

B. Transfer Learning nos datasets "SoyBean" e "ASDID"

Após a realização do *Fine Tuning*, modificamos o modelo resultante de cada arquitetura para o problema multiclasse, alterando apenas sua camada classificadora (*Fully Connected*). Contudo, apesar de modificar somente uma única camada, o treinamento pode ser considerado mais complexo e desafiador, visto que há uma variação específica e minuciosa entre cada tipo de enfermidade foliar nas plantas de soja.

Por fim, a maneira como este estudo foi conduzido buscou atingir o objetivo principal de encontrar uma rede rasa e leve, como a ResNet-18, que gerasse bons resultados para o problema central de classificação e diagnóstico de doenças na sojicultura.

IV. EXPERIMENTOS

Neste trabalho, o framework PyTorch foi utilizado para a execução dos experimentos, fornecimento das arquiteturas, transformers e respectivos pesos. As bases de dados usadas foram as três mencionadas anteriormente, aplicadas em tarefas diferentes de classificação e com propósitos variados. Em primeira instância, as três arquiteturas foram treinadas

com o dataset do "SoyNet", e a repartição usada durante o processo está detalhada na Tabela I. Vale ressaltar que já nessa primeira etapa as redes estavam pré-treinadas com os pesos usados na ImageNetV1. Esse treinamento inicial foi realizado com o objetivo de preparar e moldar os parâmetros e pesos das redes para receber imagens de folhas de soja em um problema de classificação mais complexo, uma vez que esse primeiro obstáculo trata-se de uma separação binária entre "Saudáveis" e "Doentes", usado apenas para fins adaptativos.

TABLE I
REPARTIÇÃO POR DATASET

Dataset	Treino	Teste	Total
SoyNet	5109	2190	7299
SoyBean	816	351	1167
ASDID	7024	3011	1035

Após esse processo inicial, foram utilizadas técnicas de transferência de conhecimento com o fito de treinar as mesmas redes com os pesos dos modelos já treinados com o dataset "SoyNet", apenas com a última camada descongelada e com a possibilidade de receber alterações de pesos. Sob esse contexto, as bases de dados "SoyBean" e "ASDID", com suas respectivas divisões demonstradas na Tabela I, foram responsáveis por proporcionar treinamentos multiclasse mais complexos. Assim, esses treinamentos posteriores utilizaram os ajustes resultantes do problema binário para aprofundarem-se na classificação de doenças foliares específicas, um impasse difícil, já que as diferenças entre cada enfermidade dependem de minúcias e detalhes de cada imagem.

Todos os experimentos foram realizados com as três arquiteturas propostas inicialmente: ResNet-18, ResNet-50 e ResNet-101. Além desse fator de mudança, foram realizados experimentos com as mesmas redes e bases de dados, mas modificando aspectos como otimizador (entre SGD e Adam), taxa de aprendizado (que sofreu alterações de acordo com o otimizador escolhido) e tamanho do batch, a fim de melhorar a performance conjunta. As características usadas como base na maioria dos treinamentos podem ser melhor observadas na Tabela II a seguir.

TABLE II
PARÂMETROS BASE

Parâmetro	Valor
Batch	32
Épocas	100
Learning Rate	0.0001
Função de perda	Cross Entropy

A escolha dos parâmetros foi baseada no artigo [2], visando provar que manipular parâmetros similares com uma abordagem diferente confere resultados promissores.



Fig. 1. Amostras dos datasets. Da esquerda para a direita: *SoyNet Healthy*, *SoyNet Disease*, *SoyBean Bacterial Blight* e *ASDID Potassium Deficiency*.

V. RESULTADOS

Podemos observar bons resultados no *Fine Tuning*. Apesar de ser um problema simples, é importante ressaltar que, dado o ajuste do modelo para o problema, o resultado em todas as arquiteturas foi superior a 95%, como detalhado na Tabela III e nas Figuras 2 e 3.

TABLE III
RESULTADOS *Fine Tuning*

Arquitetura	Otimizador	Dataset	Acurácia
ResNet18	SGD	SoyNet	95,39%
ResNet50	SGD	SoyNet	96,53%
ResNet101	SGD	SoyNet	95,98%

Ademais, é possível analisar que para um problema mais complexo como o de multiclass, em que foi realizado o *Transfer Learning*, foi possível obter acurácias satisfatórias, atingindo valores de até 80% nos melhores modelos. Em uma análise mais aprofundada, é observável a eficácia do otimizador "Adam" para o problema, visto que os melhores resultados entre os diferentes datasets e arquiteturas foram obtidos com ele, o que pode ser observado na Tabela IV e nas Figuras 4 e 5.

TABLE IV
RESULTADOS *Transfer Learning*

Arquitetura	Otimizador	Dataset	Acurácia
ResNet18	Adam	ASDID	87,88%
ResNet18	SGD	ASDID	86,62%
ResNet101	Adam	SoyBean	79,80%
ResNet50	Adam	SoyBean	79,77%
ResNet18	Adam	SoyBean	72,06%
ResNet101	SGD	SoyBean	75,21%
ResNet18	SGD	SoyBean	51,85%
ResNet50	SGD	SoyBean	57,83%

Em suma, os resultados foram satisfatórios, dada a diferença entre profundidade e quantidade de parâmetros das arquiteturas. Destacamos a arquitetura ResNet18, que apresentou resultados significativos, tendo como vantagem o custo-benefício

em termos de custo computacional e tempo de treinamento. Ao utilizar o mesmo dataset do estudo referência, ainda obtemos acurácias promissoras, como melhor detalhado nas Figuras 6 e 7.

TABLE V
RESULTADOS DO ARTIGO [2]

Arquitetura	Otimizador	Dataset	Acurácia
DenseNet201 (Scratch)	SGD	ASDID	96,8%
ResNet50	SGD	ASDID	95,9%

VI. CONCLUSÃO

Portanto, dada a significativa importância econômica do grão de soja no espectro global, faz-se necessário incentivar e melhorar a qualidade produtiva das lavouras de sojicultura. A fim de cumprir com essa demanda, o diagnóstico precoce de patologias nas folhas apresenta-se como um aliado, uma vez que as doenças são largamente responsáveis pelos prejuízos na produção.

Nesse contexto, visto que a detecção humana dessas anomalias é um processo custoso (pois precisa de mão de obra especializada) e, por vezes, ineficiente, há potencial para soluções automatizadas com princípios de visão computacional e inteligência artificial. Por meio dessa aptidão, diversos trabalhos foram realizados usando as chamadas CNNs (Redes Neurais Convolucionais), utilizando, em sua maioria, arquiteturas muito profundas e com número excessivo de parâmetros. Essas características geralmente conferem bons resultados, mas necessitam de grande capacidade computacional, reduzindo a acessibilidade dessas soluções automatizadas.

Assim, com o objetivo de facilitar o acesso dessas tecnologias a produtores e culturas com menos recursos, este trabalho buscou analisar CNNs mais rasas e/ou leves do que as comumente usadas, que resultassem em qualidades comparáveis ao final. Nossa principal base para comparação foi o artigo "*Soybean disease identification using original field images and transfer learning with convolutional neural networks*" [2], que faz uso de arquiteturas mais complexas, como DenseNet-201 e ResNet-50.




Fig. 2. Curva de acurácia no teste pelo TensorBoard (*Fine Tuning* com *SoyNet*).




Fig. 3. Curva de acurácia no treino pelo TensorBoard (*Fine Tuning* com *SoyNet*).

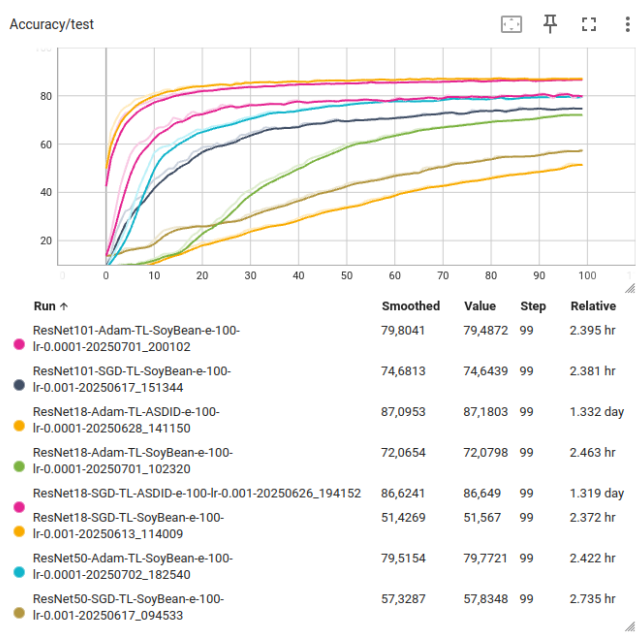


Fig. 4. Curva de acurácia no teste pelo TensorBoard (*Transfer Learning*).

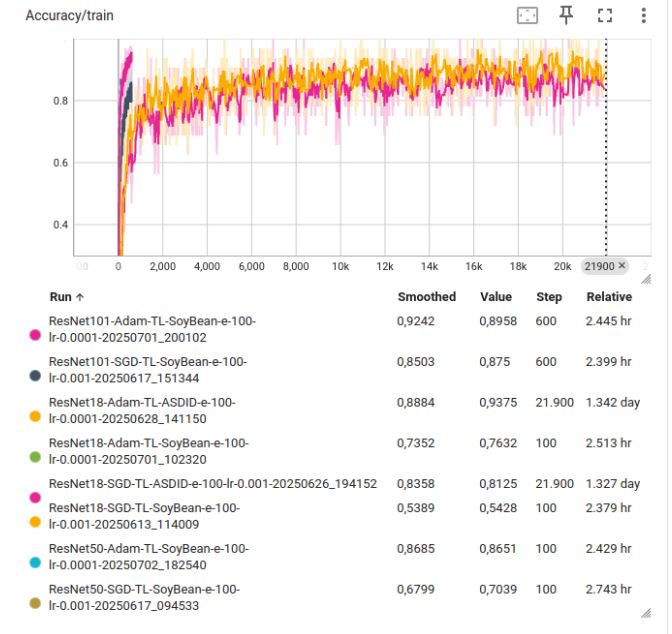


Fig. 5. Curva de acurácia no treino pelo TensorBoard (*Transfer Learning*).

Para tanto, fizemos uso de três datasets distintos e experimentamos três arquiteturas pré-treinadas com ImageNetV1 (ResNet-18, ResNet-50 e ResNet-101) com técnicas de *Fine Tuning* e *Transfer Learning*. Os resultados obtidos podem ser observados com mais detalhes nas Tabelas III e IV, porém o treinamento mais notável em nossas análises foi o da ResNet-18 com o dataset "ASDID" e otimizador "Adam".

Desse modo, tendo em vista o objetivo central de reduzir o uso computacional para o diagnóstico de doenças foliares na soja, consideramos a acurácia de 87,88%, obtida pela ResNet-18 com as características supracitadas, interessante quando comparada com as arquiteturas usadas pelo artigo de referência, no qual foram utilizadas redes mais complexas

com o dobro de parâmetros, como a DenseNet-201, que atingiu uma acurácia de 96,8% (DenseNet-201 possui por volta de vinte milhões de parâmetros, enquanto a ResNet-18 se aproxima dos onze milhões). Por fim, julgamos intrigante e encorajadora a diferença de cerca de dez pontos percentuais, dada a drástica redução no gasto de poder computacional, o que confere maior acessibilidade a todo tipo de produtor.

REFERENCES

- [1] J. P. Molina, R. C. Meyer, C. A. M. Souza, F. L. A. Lobo, and R. C. Wrather, "Doenças da soja e perdas associadas no brasil e no mundo," in *Embrapa Soja – Documentos 406*. Londrina, PR: Embrapa, 2019, pp. 107–120. [Online]. Available: <https://www.alice.cnptia.embrapa.br/alice/bitstream/doc/1110682/1/aMolinap107.pdf>
- [2] N. Bevers, E. J. Sikora, and N. B. Hardy, "Soybean disease identification using original field images and transfer learning with convolutional neural networks," *Computers and Electronics in Agriculture*, vol. 203, p. 107449, 2022. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0168169922007578>
- [3] —, "Pictures of diseased soybean leaves by category captured in field and with controlled backgrounds: Auburn soybean disease image dataset (asdid)," <https://doi.org/10.5061/dryad.6q573n5z8>, 2022, dataset.
- [4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [5] A. S. Rajput, S. Shukla, and S. Thakur, "Soynet: A high-resolution indian soybean image dataset for leaf disease classification," *Data in Brief*, vol. 49, p. 109447, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2352340923005474>
- [6] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "Imagenet: A large-scale hierarchical image database," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 248–255, 2009.